

Notas de implementação: regiões conformais para a trajetória completa

Rafael Izbicki

28 de agosto de 2026

1. O que queremos mudar

Atualmente a parte conformal do trabalho calibra um quantil separado para cada horizonte futuro. Isso produz cinco círculos, cada um com cobertura próxima de 90% *isoladamente*, e todos com o mesmo raio para todos os jogadores e todas as jogadas. Duas limitações:

- não há uma garantia sobre a cobertura da trajetória inteira;
- a largura não distingue um jogador correndo em linha reta de um jogador disputando a bola.

As duas seções seguintes resolvem esses dois pontos com uma única construção. Notação: para a jogada k , o jogador i e o horizonte $t \in \mathcal{H} = \{26, \dots, 30\}$, sejam $\mathbf{p}_i^{(t)} \in \mathbb{R}^2$ a posição real, $\hat{\mathbf{p}}_i^{(t)}$ a prevista pelo Social-LSTM e

$$e_{i,t} = \|\mathbf{p}_i^{(t)} - \hat{\mathbf{p}}_i^{(t)}\|_2.$$

2. Um único score para toda a trajetória

A ideia é escrever o raio da região no horizonte t como o produto de duas peças com papéis distintos:

$$r_t = \hat{q} \cdot \hat{s}_t,$$

onde $\hat{s}_t$ é a forma da banda (como o erro típico cresce com o horizonte), estimada no treino, e $\hat{q}$ é a escala global, obtida na calibração.

Passo 1 (treino): estimar $\hat{s}_t$. Com resíduos out-of-fold do treino, uma escolha possível é $\hat{s}_t = \text{median}_i e_{i,t}$.

Passo 2 (calibração): o score. Para cada unidade de calibração (Seção 3), calcule o maior erro normalizado ao longo dos cinco segundos:

$$R = \max_{t \in \mathcal{H}} \frac{e_t}{\hat{s}_t}. \quad (1)$$

Com n scores de calibração, tome $\hat{q}$ como a estatística de ordem $\lceil (n+1)(1-\alpha) \rceil$ da amostra ordenada dos R 's.

Passo 3 (previsão). Para uma nova jogada, a região no horizonte t é o círculo

$$\mathcal{C}_t = \{\mathbf{p} : \|\mathbf{p} - \hat{\mathbf{p}}^{(t)}\|_2 \leq \hat{q} \hat{s}_t\}.$$

A leitura é simultânea: o alvo é que todos os pontos futuros caiam nos respectivos círculos.

3. Unidade de calibração: o que exatamente fica garantido

A escolha da unidade de calibração determina qual afirmação probabilística o método entrega. Há duas opções naturais, e elas garantem coisas bem diferentes.

Alvo A (por jogada). A unidade é a sequência ofensiva, e o score agrega os 20 jogadores:

$$R_k = \max_i \max_{t \in \mathcal{H}} \frac{e_{k,i,t}}{\hat{s}_t}.$$

A garantia é

$$\mathbb{P}(\text{as 20 trajetórias inteiras dentro das suas bandas}) \geq 1 - \alpha,$$

válida em amostra finita, porque a jogada é a unidade permutável: as jogadas de calibração e a jogada nova são trocáveis entre si. Em compensação, $\hat{q}$ é o quantil de um máximo sobre 20 jogadores, o que produz bandas largas.

Alvo B (por jogador dentro da jogada). A unidade é o par (k, i) , e o score é apenas o máximo no tempo:

$$R_{k,i} = \max_{t \in \mathcal{H}} \frac{e_{k,i,t}}{\hat{s}_t}.$$

O alvo passa a ser

$$\mathbb{P}(\text{a trajetória inteira de um dado jogador dentro da sua banda}) \geq 1 - \alpha,$$

que costuma ser o que de fato se quer, e é a leitura natural do capítulo atual. A garantia de amostra finita, porém, não vale nessa forma direta. Os $n = 20 \times$ (número de jogadas) scores não são permutáveis com o score de teste: os 20 jogadores de uma mesma jogada dividem a bola, o contexto tático e o grau de caos daquela sequência, enquanto o score de teste vem de uma jogada nova. O quantil empírico continua estimando o quantil populacional certo, sem viés sistemático, mas o tamanho efetivo de amostra é o número de **jogadas**, não o de trajetórias: com 164 jogadas, $n = 3280$ é ilusório e $\hat{q}$ flutua como se $n \approx 164$.

Como proceder. O Alvo B merece ser rodado assim mesmo, como um *conformal naive*, com a cobertura empírica medida por repetições feitas ao nível da jogada. Uma cobertura próxima de $1 - \alpha$ é um resultado empírico legítimo, desde que reportado como tal e não como garantia. A variante exata do mesmo alvo serve de aferição: sorteando **um** jogador por jogada de calibração, as unidades voltam a ser permutáveis com a unidade de teste (um jogador sorteado de uma jogada nova) e a garantia é recuperada, ao custo de descartar 19 de cada 20 trajetórias. Valores próximos de $\hat{q}$ nas duas versões indicam que a dependência dentro da jogada não está atrapalhando. A Seção 6 obtém o Alvo B com garantia exata e sem esse descarte.

4. Sofisticação: escala adaptativa

Um passo natural é permitir que a escala dependa da situação, e não apenas do horizonte. Seja $\mathbf{x}_i$ a informação disponível sobre o jogador i no último instante observado ($T_{\text{obs}} = 25$). Queremos substituir $\hat{s}_t$ por

$$\hat{s}_t(\mathbf{x}_i),$$

uma função que estima o tamanho típico do erro daquele jogador naquele horizonte. Um jogador em movimento retilíneo e isolado recebe uma região menor; um jogador disputando a bola em área congestionada recebe uma região maior.

Como estimar. Isso é um problema de regressão comum, e qualquer método serve. Usando resíduos out-of-fold do treino, monte a base com resposta $e_{i,t}$ e preditores $(\mathbf{x}_i, t)$, e ajuste

$$\log(e_{i,t} + \varepsilon) = g(\mathbf{x}_i, t) + \text{erro}, \quad \hat{s}_t(\mathbf{x}_i) = \exp\{\hat{g}(\mathbf{x}_i, t)\}.$$

(onde ε é um número bem pequeno). O ajuste na escala log evita valores negativos. O método $\hat{g}$ pode ser regressão linear, floresta aleatória, gradient boosting ou uma rede pequena. Incluir t como preditor em um único modelo tende a aproveitar melhor os poucos dados disponíveis do que ajustar cinco modelos separados.

Uma possibilidade é usar a representação da própria rede: depois de treinar o Social-LSTM, congele a rede e use como preditores a última camada oculta antes da saída (o estado latente $\mathbf{s}_i^{(t)}$ do decodificador, ou $\mathbf{h}_i^{(T_{\text{obs}})}$ do codificador). Sobre esses vetores, ajuste um modelo simples, tipicamente uma regressão linear em $\log(e_{i,t} + \varepsilon)$ com regularização.

Nessa abordagem, o score (1) passa a ser $R = \max_t e_{i,t} / \hat{s}_t(\mathbf{x}_i)$ e o raio, $r_{i,t} = \hat{q} \hat{s}_t(\mathbf{x}_i)$. O modelo de escala deve ser ajustado apenas com dados de treino.

5. Cross-conformal

Separar um conjunto de calibração custa caro quando há poucas sequências, e um $\hat{q}$ baseado em poucas dezenas de scores é instável. A alternativa é o *cross-conformal* (Vovk, 2015; Barber et al., 2021):

1. particione as jogadas em K dobras (por exemplo, $K = 5$ ou 10);
2. para cada dobra k , treine a rede e ajuste o modelo de escala nas demais $K - 1$ dobras, e calcule os scores R das jogadas da dobra k ;
3. junte os scores das K dobras em uma única amostra de tamanho n e obtenha $\hat{q}$ como na Seção 2;
4. para uma nova jogada, use a rede treinada com todos os dados (ou a média das K previsões).

Assim toda jogada contribui para a calibração. A cobertura empírica costuma ficar próxima de $1 - \alpha$, com garantia de pior caso da ordem de $1 - 2\alpha$. A partição deve sempre ser feita por sequência ofensiva completa: jogadores e instantes de uma mesma jogada nunca podem ser divididos entre dobras. Dentro de cada dobra, os resíduos que alimentam o modelo de escala também precisam ser out-of-fold, o que pede um split interno nas $K - 1$ dobras de treino.

6. Ideia extra: controle de risco

O Alvo B da Seção 3 pode ser obtido com garantia exata se for reescrito como uma esperança. Sorteando um jogador I uniformemente entre os N de uma jogada nova,

$$\mathbb{P}(\text{o jogador } I \text{ escapa da sua banda}) = \mathbb{E}_{\text{jogada}} \left[\frac{1}{N} \sum_{i=1}^N \mathbf{1}\{\text{o jogador } i \text{ escapa}\} \right].$$

Controlar a fração esperada de jogadores fora da banda é, portanto, a mesma coisa que garantir o Alvo B. A unidade permutável volta a ser a jogada, com os 20 jogadores agregados dentro da unidade, de modo que toda a informação disponível é usada sem tratar as 3280 trajetórias como independentes. É exatamente isso que o *conformal risk control* (Angelopoulos et al., 2024) faz.

Defina, para a jogada k e um raio candidato λ , a perda

$$L_k(\lambda) = \frac{1}{N} \sum_{i=1}^N \mathbf{1} \left\{ \max_{t \in \mathcal{H}} \frac{e_{k,i,t}}{\hat{s}_t(\mathbf{x}_{k,i})} > \lambda \right\},$$

isto é, a fração de jogadores cuja trajetória sai da banda. Ela é não crescente em λ , única condição exigida pelo método. Com n jogadas de calibração, escolha

$$\hat{\lambda} = \inf \left\{ \lambda : \frac{n}{n+1} \frac{1}{n} \sum_{k=1}^n L_k(\lambda) + \frac{1}{n+1} \leq \alpha \right\},$$

e use os raios $r_{i,t} = \hat{\lambda} \hat{s}_t(\mathbf{x}_i)$. O resultado é $\mathbb{E}[L_{\text{nova}}(\hat{\lambda})] \leq \alpha$.

A garantia é uma média sobre jogadas novas, e não uma afirmação sobre uma jogada específica: numa sequência caótica, metade dos jogadores pode sair da banda sem que nada seja violado. Tampouco se afirma algo sobre os 20 jogadores simultaneamente, que é o Alvo A. Em compensação, $\hat{\lambda}$ costuma ficar bem menor que o $\hat{q}$ do Alvo A, com bandas visualmente mais úteis.

Referências

- J. Diquigiovanni, M. Fontana, S. Vantini (2022). *Conformal prediction bands for multivariate functional data*. Journal of Multivariate Analysis, 189, 104879.
<https://doi.org/10.1016/j.jmva.2021.104879>
- Y. Zhou, L. Lindemann, M. Sesia (2024). *Conformalized adaptive forecasting of heterogeneous trajectories*. ICML 2024.
<https://arxiv.org/abs/2402.09623>
- V. Vovk (2015). *Cross-conformal predictors*. Annals of Mathematics and Artificial Intelligence, 74, 9–28.
<https://arxiv.org/abs/1208.0806>
- R. F. Barber, E. J. Candès, A. Ramdas, R. J. Tibshirani (2021). *Predictive inference with the jackknife+*. Annals of Statistics, 49(1), 486–507.
<https://arxiv.org/abs/1905.02928>
- A. N. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster (2024). *Conformal risk control*. ICLR 2024.
<https://arxiv.org/abs/2208.02814>